ATIVIDADE AVALIATIVA

Trabalho Prático de Deep Learning

Modelagem, hiperparametrização e avaliação experimental

Informação	Definição
Prazo de entrega e apresentação	Até 15 de outubro
Tempo de Apresentação (slides)	15min
Formação do grupo	Até 3 estudantes
Fonte dos dados	Conjunto de dados disponível no Portal Brasileiro de Dados Abertos
Escolha metodológica	Uma das quatro frentes descritas neste documento

Objetivo geral. Desenvolver e avaliar uma solução de deep learning para um problema de classificação ou regressão definido pelo grupo. O trabalho deverá demonstrar domínio do conjunto de dados, do pré-processamento, da construção da arquitetura, da busca de hiperparâmetros e da análise crítica dos resultados, incluindo a relação entre desempenho, custo computacional e capacidade de generalização.

1 Proposta do trabalho

Cada grupo deverá escolher um conjunto de dados público e formular um problema de classificação ou regressão a partir de uma variável alvo claramente definida. A escolha precisa ser compatível com a frente selecionada e deve permitir uma avaliação experimental consistente. O conjunto de dados deverá ser obtido no Portal Brasileiro de Dados Abertos. Dois grupos não poderão selecionar o mesmo dataset.

Antes do treinamento, o grupo deverá explicar o contexto do problema, a utilidade da previsão, a unidade de observação e o significado da variável alvo. Também deverá indicar se o problema é de classificação binária, classificação multiclasse, classificação multilabel ou regressão.

2 Requisitos comuns a todas as frentes

2.1 Descrição do problema e dos dados

- Descrever as variáveis de entrada e a variável alvo, incluindo seus tipos, unidades e possíveis limitações.
- Apresentar estatísticas descritivas e visualizações adequadas das distribuições, bem como a frequência de valores ausentes, duplicados e valores potencialmente anômalos.
- Analisar a distribuição da variável alvo. Em classificação, verificar o balanceamento entre classes; em regressão, examinar faixa, dispersão, assimetria e valores externos.
- Justificar a seleção, transformação ou exclusão de atributos, observando o risco de vazamento de informação da variável alvo para as entradas.

2.2 Pré processamento

O pré-processamento deverá ser adequado à arquitetura e ao tipo de dado. Quando aplicável, deverá incluir normalização ou padronização de variáveis numéricas, codificação one hot ou outra codificação justificada para variáveis categóricas, tratamento de dados ausentes, tratamento de classes desbalanceadas e transformação dos dados para o formato de entrada da rede.

Os parâmetros das transformações deverão ser estimados somente com os dados de treinamento e depois aplicados aos conjuntos de validação e teste. Essa regra também se aplica ao treinamento de autoencoders usados como pré-processamento (na frente de autoencoders).

2.3 Separação entre treino validação e teste

Partição	Finalidade
Treinamento	Ajustar os pesos da rede e estimar transformações de pré-processamento.
Validação	Selecionar arquitetura, hiperparâmetros, limiar de decisão e critérios de parada.
Teste	Estimar o desempenho final do procedimento escolhido.

A estratégia de divisão deverá respeitar a estrutura dos dados. Em classificação, recomenda-se preservar a proporção das classes quando isso for possível. Em séries temporais, a divisão deverá ser cronológica, sem embaralhamento e sem usar observações futuras para prever o passado. Se houver indivíduos, municípios, equipamentos ou outras unidades com várias observações, o grupo deverá considerar uma divisão por grupos para impedir que a mesma unidade apareça em partições diferentes. Opcionalmente, poderá ser adotada a estratégia de validação cruzada (k-fold cross validation) com múltiplas separações de treino/validação/teste para lidar com a variância dos experimentos (especialmente em coleções pequenas).

2.4 Hiperparametrização

Todos os modelos deverão ser hiperparametrizados. Recomenda-se o uso do Optuna para explorar os hiperparâmetros com maior potencial de alterar o desempenho, a generalização e o custo do treinamento. Não basta informar os valores encontrados: o grupo deverá justificar quais hiperparâmetros entraram na busca, os intervalos de parâmetros adotados, o número de tentativas e a métrica otimizada.

Elemento	Exigência
Espaço de busca	Definir intervalos plausíveis.
Parâmetros prioritários	Priorizar taxa de aprendizado, largura, profundidade, batch size, regularização, dropout, critério de parada, e parâmetros próprios da frente escolhida.
Métrica de avaliação	Selecionar uma métrica coerente com o problema e calculada apenas na validação durante a busca.

A amplitude da busca deverá ser compatível com o problema e com os recursos disponíveis. O grupo deverá explicar por que cada intervalo é informativo e evitar buscas extensas em hiperparâmetros com baixa influência esperada. Os resultados deverão mostrar como as escolhas afetaram a métrica de validação, o tempo de treinamento e os sinais de overfitting.

2.5 Avaliação experimental

- Definir ao menos uma métrica principal e métricas complementares adequadas ao problema.
- Em classificação, considerar medidas como acurácia, precisão, revocação, MacroF1 e matriz de confusão.
- Em regressão, considerar medidas como MAE, RMSE e R^2, explicando o significado dos erros na unidade da variável alvo.
- Apresentar curvas de treinamento e validação para discutir convergência, subajuste e overfitting.
- Comparar modelos sob o mesmo protocolo de dados e relatar tempo de treinamento, tempo de inferência ou outro indicador de custo relevante.
- Discutir limitações, fontes de incerteza e situações em que o modelo pode falhar.

3 Frentes de desenvolvimento

O grupo deverá escolher somente uma das frentes a seguir e cumprir os requisitos específicos correspondentes, além de todos os requisitos comuns.

3.1 Multilayer perceptrons

O grupo deverá construir integralmente uma MLP adequada ao problema, definindo as camadas de entrada, camadas ocultas, funções de ativação e camada de saída. A análise deverá abranger a largura e a profundidade da rede, diferentes estratégias de regularização e a interação entre capacidade, custo e generalização.

- Investigar o efeito do número de camadas ocultas e do número de neurônios por camada.
- Comparar estratégias de regularização, como dropout, regularização L1 ou L2, normalização e parada antecipada, conforme sua pertinência.
- Selecionar e comparar ao menos três variações promissoras de arquitetura resultantes da análise ou da busca de hiperparâmetros.
- Avaliar desempenho, tempo de treinamento, quantidade de parâmetros e diferença entre as curvas de treino e validação.

- Explicar quais variações apresentaram subajuste ou overfitting e como a regularização alterou esses comportamentos.

3.2 Redes recorrentes

O grupo deverá modelar um problema de séries temporais multivariadas, usando a evolução temporal de múltiplos atributos de entrada para predizer ao menos uma variável alvo no tempo. A construção dos exemplos e a avaliação deverão preservar a ordem temporal.

- Comparar SimpleRNN, GRU e LSTM sob condições experimentais equivalentes.
- Avaliar a quantidade de camadas recorrentes e de unidades por camada, relacionando capacidade e custo computacional.
- Investigar diferentes tamanhos de janela coerentes com a dinâmica do fenômeno e explicar o horizonte de previsão adotado.
- Avaliar dependências de longo prazo, discutindo se janelas maiores melhoram a previsão e como afetam custo, estabilidade e overfitting.
- Relatar a estratégia de previsão, por exemplo um passo ou múltiplos passos à frente, e as dimensões de entrada e saída.
- Comparar tempo de treinamento e efetividade das três famílias recorrentes.

3.3 Redes de convolução

O grupo deverá aplicar redes convolucionais a dados compatíveis com convolução, como imagens ou representações estruturadas cuja vizinhança tenha significado. Deverão ser comparadas ao menos três arquiteturas pertencentes a famílias diferentes, por exemplo ResNet, VGG e GoogLeNet.

- Comparar ao menos três famílias de arquiteturas convolucionais e justificar a adequação de cada uma ao conjunto de dados.
- Avaliar o impacto de treinar somente das camadas finais, mantendo as demais camadas congeladas, vs o treinamento da rede completa.
- Comparar inicialização com pesos pré-treinados e treinamento a partir de pesos aleatórios.
- Avaliar o efeito de data augmentation, escolhendo transformações que preservem o rótulo e sejam plausíveis no domínio dos dados.
- Controlar resolução de entrada, número de épocas e demais condições para que as comparações sejam interpretáveis.
- Discutir desempenho, tempo, memória, quantidade de parâmetros treináveis e sinais de overfitting.

3.4 Autoencoders

O grupo deverá investigar o autoencoder como método de representação e pré-processamento. O treinamento do autoencoder deverá utilizar somente os dados de treinamento, e suas transformações deverão ser aplicadas posteriormente à validação e ao teste.

- Treinar uma representação com espaço latente de duas dimensões e visualizar os dados, colorindo os pontos pela variável alvo quando isso for aplicável. Interpretar agrupamentos, sobreposições e valores isolados.
- Avaliar o autoencoder para remoção de ruído, adicionando uma perturbação justificada às entradas e medindo a qualidade da reconstrução e seu efeito na tarefa final.
- Avaliar o autoencoder para imputação de dados ausentes, definindo uma estratégia de mascaramento e comparando valores reconstruídos com valores conhecidos ocultados durante a avaliação.
- Avaliar a compactação das features por meio de uma representação latente com dimensão menor que a entrada original.
- Usar as features compactadas como entrada de uma MLP e comparar seu desempenho com o de uma MLP treinada diretamente sobre as features originais.
- Manter comparáveis as configurações da tarefa supervisionada e discutir desempenho, custo, robustez e perda de informação.

4 Entregáveis

- Relatório técnico com identificação dos integrantes, link e descrição do conjunto de dados, definição do problema, metodologia, experimentos, resultados, discussão e conclusões.
- Link do github com o código desenvolvido.
- Registro da busca de hiperparâmetros, incluindo espaço de busca, configuração do estudo, melhores tentativas e justificativa da configuração final.
- Tabelas e gráficos que permitam comparar as arquiteturas ou estratégias exigidas na frente escolhida.

5 Estrutura sugerida para o relatório

1. Introdução e objetivo do problema.
2. Descrição da fonte e caracterização do conjunto de dados.
3. Arquiteturas, espaço de busca e protocolo de hiperparametrização.
4. Resultados de validação e seleção dos modelos promissores.
5. Avaliação final no conjunto de teste e análise de custo vs efetividade.
6. Limitações e conclusões.

6 Critérios de Avaliação

I) Justificativas das escolhas necessárias para construção e avaliação do método desenvolvido (3pts).
II) Corretude da modelagem das arquiteturas na aplicação (2pts).
III) Domínio de estratégias de hiperparametrização (2pts).
IV) Domínio na interpretação dos resultados (2pts).