INSTITUTO FEDERAL DE GOIÁS · DISCIPLINA DEEP LEARNING · TRABALHO PRÁTICO

Previsão de volume de tráfego em praças de pedágio com redes recorrentes

Relatório técnico · Frente 3.2 (Redes recorrentes) · Outubro de 2026

Integrantes	Daniel Flavio · Guilherme Martins
Repositório (código)	https://github.com/danflavio/pracas-pedagio-dl
Conjunto de dados	ANTT · Volume de Tráfego nas Praças de Pedágio (Portal Brasileiro de Dados Abertos), arquivos diários de 2024, 2025 e 2026. Licença CC BY. https://dados.antt.gov.br/dataset/volume-trafego-praca-pedagio
Tarefa	Regressão em série temporal multivariada, previsão um passo à frente (t+1)

1. Introdução e objetivo

As concessionárias de rodovias federais registram, por dia, quantos veículos passam em cada praça de pedágio. Prever esse volume com um dia de antecedência apoia o dimensionamento de cabines e equipes, a estimativa de arrecadação e o planejamento de feriados.

- **Unidade de observação:** uma praça de pedágio (par concessionária + praça) em um dia.
- **Variável alvo:** total de veículos na praça no dia seguinte (t+1), em veículos/dia (contínua, não negativa).
- **Tipo de problema:** regressão. Estratégia direta de um passo: a rede recebe os W dias anteriores (13 atributos por dia) e devolve um único valor.
- **Objetivo experimental:** comparar SimpleRNN, GRU e LSTM sob as mesmas condições e analisar janela, profundidade, largura, custo computacional e generalização.

2. Fonte e caracterização dos dados

2.1 Estrutura

Item	Valor
Período	01/01/2024 a 31/08/2026 (974 dias)
Linhas	9.184.154 (2024: 3.312.763 · 2025: 3.274.157 · 2026: 2.597.234)
Colunas (8)	`concessionaria`, `praca`, `mes_ano` (data), `sentido`, `tipo_cobranca`, `categoria_eixo`, `tipo_de_veiculo`, `volume_total`
Concessionárias / praças	43 / 345
Volume total	2.379.466.795 veículos

CSV com separador ";", decimal "," e codificação Latin-1. O hash SHA-256 de cada arquivo está em `data_manifest.json`.

2.2 Qualidade dos dados

Aspecto	Achado	Tratamento
Granularidade	`mes_ano`, apesar do nome, é uma data diária (366, 365 e 243 datas distintas por ano).	Modelagem diária; alvo em t+1.
Ausentes	A ausência aparece como dias inteiros sem registro: entre as 303 praças usadas, 106 têm lacunas, somando 1.613 dias.	Janela aceita só se todos os dias (entrada e alvo) foram observados. Nada é interpolado.

Aspecto	Achado	Tratamento
Cobertura	Só 47 das 345 praças cobrem os 974 dias; mediana de 432 dias.	Modelo global (uma rede para todas as praças). Filtro de ≥ 180 dias: 303 praças.
Duplicados	4.853 chaves repetidas (0,15%), todas em jan–mar/2025; nenhuma entre arquivos.	Volumes somados na agregação praça × dia.
Inconsistências	"Veículo Pequeno" só existe em 2024 (≈ 0% do volume). `categoria_eixo` mistura códigos e rótulos em 2025.	Categoria excluída; `categoria_eixo` agregada (não usada).
Anômalos	Critério 3 × IQR por praça: 3.751 dias (2,09%), 2,59% do volume. Os maiores são eventos reais (Réveillon na Autopista Litoral Sul, 2,4× o limite).	Mantidos: removê-los esconderia os dias mais difíceis de prever.

2.3 Distribuição da variável alvo

No nível de linha, `volume_total` não tem zeros nem negativos (mínimo 1) e tem assimetria de 14,9, com cauda longa à direita (Fig. 1a). Agregado por praça e dia, o alvo tem média de ≈ 13,2 mil veículos e desvio-padrão de ≈ 12,2 mil no treino[1]. A dispersão vem sobretudo do porte das praças: algumas passam de 80 mil veículos/dia, bem acima da média. Há padrão semanal claro, com sexta-feira como o dia mais movimentado (Fig. 1b), e picos sazonais como o Réveillon e lacunas por início de operação (Fig. 2).

[1] Desvio-padrão obtido de RMSE/$\sqrt{(1 - R^2)}$ da persistência no treino (RMSE 3.133; R^2 0,934).

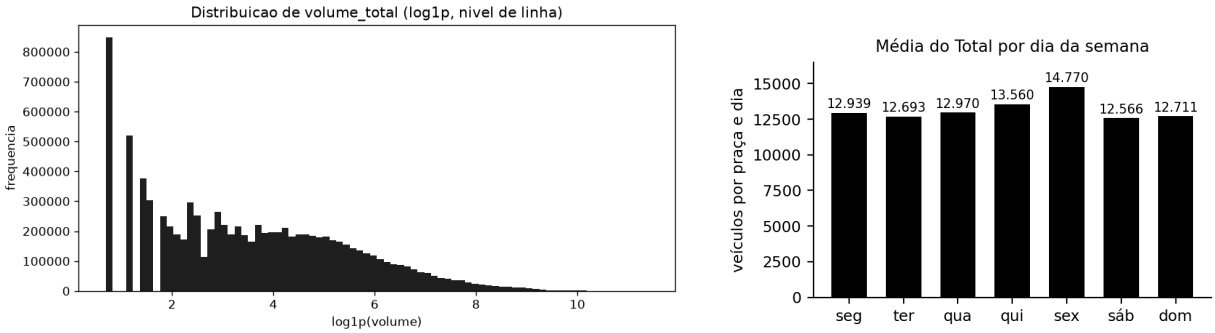


Figura 1. (a) Distribuição de `volume_total` por linha, em escala log1p. (b) Média do alvo por dia da semana.

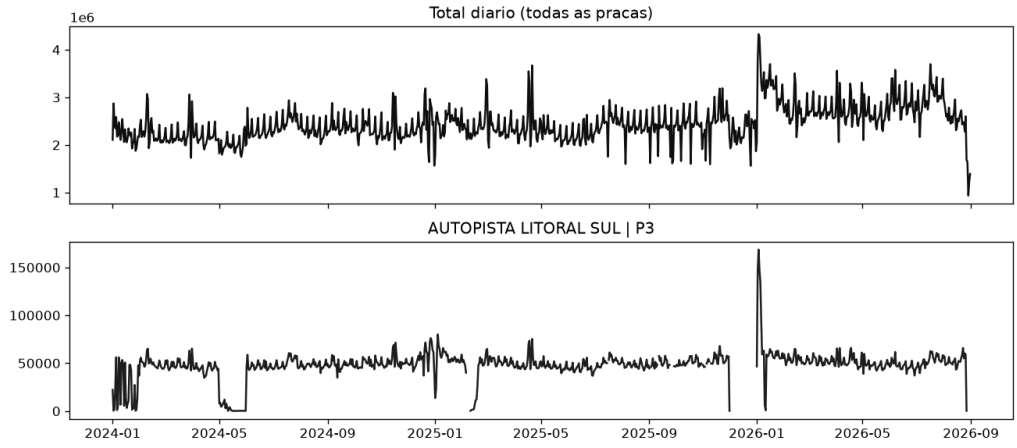


Figura 2. Total diário de todas as praças e uma praça com lacunas e pico de Réveillon (Autopista Litoral Sul, P3).

2.4 Atributos de entrada e risco de vazamento

Atributo	Tipo	Unidade	Origem
Passeio, Comercial, Moto	numérico contínuo	veículos/dia	soma de `volume_total` por tipo de veículo
Total	numérico contínuo	veículos/dia	soma dos três tipos (valor dos dias anteriores)
dow_0 … dow_6	binário (one-hot)	–	dia da semana
mes_sin, mes_cos	contínuo em $[-1, 1]$	–	mês em codificação cíclica

`sentido`, `tipo_cobranca` e `categoria_eixo` foram somados, pois o alvo é o total da praça. Identificadores de praça não entram como atributo: o modelo aprende só da dinâmica da série, o que permite aplicá-lo a praças novas. **Vazamento:** a janela contém apenas os dias $t-W+1$ a t; o total de $t+1$ nunca está na entrada, e o calendário é conhecido de antemão.

3. Metodologia

3.1 Pré-processamento

1. Agregação para praça × dia × tipo de veículo; tipos em colunas; Total = soma. Em dia observado, tipo sem registro recebe 0 (o bruto só registra volumes > 0).
2. Filtro de praças com ≥ 180 dias e reconstrução do calendário diário, marcando dias não observados (180.737 linhas, 179.124 observadas).
3. Calendário: dia da semana em one-hot (7) e mês em seno/cosseno (2).
4. Janelas deslizantes de W dias (passo 1). Entrada X com dimensão ($W \times 13$) e saída y escalar (Total de $t+1$).
5. Padronização z-score dos 4 canais de volume com média e desvio **somente do treino** (float64). O alvo usa a escala do canal Total; as métricas são calculadas depois de voltar a veículos.

Com $W = 30$ e divisão cronológica: treino $105.754 \times 30 \times 13$, validação $30.678 \times 30 \times 13$, teste $27.467 \times 30 \times 13$.

3.2 Divisão entre treino, validação e teste

Protocolo	Treino	Validação	Teste	Mede
Cronológico (data do alvo)	até 30/11/2025	01/12/2025 a 30/04/2026	01/05 a 31/08/2026	o futuro de praças conhecidas
Por grupos (praças)	70% das praças	15%	15%	praças nunca vistas

Nada é embaralhado. O corte pela data do alvo garante que o alvo mais recente do treino é anterior ao mais antigo da validação, o que é verificado automaticamente em `src/dataset.py`. As praças são sorteadas com semente 42, de modo que nenhuma aparece em duas partições. A validação serve para early stopping, busca e escolha do modelo; o teste é usado uma única vez. Não houve validação cruzada (opcional), por custo.

3.3 Arquiteturas e treino

```
Entrada (W × 13) → L camadas recorrentes [SimpleRNN | GRU | LSTM] com U unidades → Dense(1) linear
```

As três famílias usam a mesma estrutura e a mesma semente; muda só a célula. Nas $L-1$ primeiras camadas, `return_sequences=True`. Perda MSE no alvo padronizado; Adam ou RMSprop com `clipnorm = 1,0` (contra gradiente explosivo); EarlyStopping na perda de validação (paciência 6, restaura os melhores pesos) e ReduceLROnPlateau (fator 0,5, paciência 3). TensorFlow/Keras, apenas CPU.

3.4 Métricas e baselines

MAE é a métrica principal (erro médio em veículos/dia). **RMSE** pesa mais os erros grandes e foi a métrica otimizada na busca, coerente com a perda MSE. **R^2** é complementar. Baselines obrigatórios: **persistência** ($\hat{y}_{t+1} = y_t$) e **média móvel** da janela. Custo: parâmetros treináveis, tempo de treino e tempo de inferência por previsão (lote de validação ÷ nº de janelas).

4. Hiperparametrização

4.1 Espaço de busca

Hiperparâmetro	Intervalo	Justificativa
Célula	SimpleRNN, GRU, LSTM	objeto da frente 3.2
Janela W	7, 14, 30 dias	uma semana, duas semanas e um mês: ciclos semanal e mensal
Unidades U	32 a 128 (log)	largura; efeito multiplicativo no nº de parâmetros
Camadas L	1, 2	profundidade; 3 camadas avaliada à parte (Seção 5.3), por custo
Dropout	0 a 0,3	regularização leve; o conjunto tem mais de 100 mil janelas
Taxa de aprendizado	10^{-4} a 5×10^{-3} (log)	faixa usual de Adam e RMSprop
Batch	128, 256	64 descartado por custo: 21,1 s/época contra 10,2 s com 256
Otimizador	Adam, RMSprop	os mais usados em redes recorrentes

Configuração do estudo: Optuna com amostrador TPE (padrão) e MedianPruner (5 tentativas iniciais, 5 épocas de aquecimento); 15 tentativas; objetivo = minimizar o RMSE na validação; até 40 épocas com paciência 5. Por orçamento de CPU, cada tentativa treinou em 50% do treino (subamostragem sistemática, sem embaralhar), com a validação completa. Registro: `results/optuna_trials.csv` e `results/optuna_resumo.json`.

4.2 Resultados da busca

Tabela 1. Tentativas completas, ordenadas pelo RMSE de validação (veículos).

#	Célula	W	U	L	Dropout	Taxa	Batch	Otim.	Épocas	Tempo (s)	RMSE
12	**SimpleRNN**	**30**	**54**	**1**	**0,10**	**1,4e-3**	**128**	**RMSprop**	**35**	**90**	**2.770**
14	SimpleRNN	30	36	1	0,05	9,5e-4	128	RMSprop	28	54	2.774
1	SimpleRNN	7	65	2	0,10	2,7e-4	128	Adam	35	89	2.972
5	GRU	30	63	1	0,21	8,4e-4	128	RMSprop	27	181	3.502
0	GRU	14	43	2	0,08	1,7e-4	256	RMSprop	35	130	3.721
2	SimpleRNN	14	50	1	0,20	2,1e-3	128	Adam	9	18	3.835
4	SimpleRNN	7	103	2	0,24	3,2e-3	256	RMSprop	29	58	3.915
11	GRU	30	58	1	0,29	4,4e-4	128	RMSprop	5	33	4.266
3	GRU	14	45	2	0,20	4,0e-3	256	Adam	5	23	4.472

- 9 tentativas completas e 6 interrompidas pelo pruner (5 delas com janela de 7 dias). As duas melhores usam janela de 30 dias.
- As melhores combinam dropout baixo e taxa perto de 10^{-3}. As tentativas 11 e 3 rodaram só 5 épocas e ficaram entre as piores.
- Uma tentativa com GRU custou cerca de 2× uma com SimpleRNN de tamanho parecido.
- A LSTM não foi amostrada em nenhuma tentativa (as 10 primeiras do TPE são aleatórias). Por isso a comparação entre famílias foi feita em experimento controlado (Seção 5.1).

4.3 Escolha da configuração final

A vencedora da busca (tentativa 12), retreinada com o treino completo, teve MAE 1.566 e RMSE 2.725 na validação; a melhor variante derivada dela chegou a MAE 1.493. A configuração de referência usada no piloto (**GRU, W = 30, 1 camada de 64 unidades, sem dropout, Adam com taxa 10^{-3}, batch 64**, até 60 épocas, paciência 6) teve **MAE 1.108 e RMSE 2.539**, melhor nas duas métricas. Ela foi adotada como modelo final, com escolha feita apenas na validação. A interpretação é que o orçamento da busca (15 tentativas, metade do treino, sem batch 64) foi pequeno demais para superar uma configuração padrão.

5. Resultados de validação (frente 3.2)

As Seções 5.1 a 5.3 fixam a receita da busca (U = 54, RMSprop, taxa $1{,}4 \times 10^{-3}$, dropout 0,10, batch 128), treinam com o treino completo e variam um fator por vez. Os valores são comparáveis entre si. Persistência na validação: MAE 1.470, RMSE 3.101, R^2 0,941.

5.1 SimpleRNN, GRU e LSTM

Tabela 2. Famílias sob duas receitas de treino (W = 30, 1 camada).

Receita	Célula	MAE	RMSE	R^2	Parâmetros	Épocas	Treino (s)	s/época	ms/previsão
Busca (U = 54)	SimpleRNN	1.566	2.725	0,955	3.727	31	170	5,5	0,11
	GRU	1.537	2.702	0,955	11.233	43	546	12,7	0,14
	LSTM	1.550	2.747	0,954	14.743	34	428	12,6	0,15
Referência (U = 64)	SimpleRNN	1.249	2.564	0,960	5.057	60	489	8,1	–
	GRU	**1.108**	**2.539**	**0,961**	15.233	48	958	20,0	–
	LSTM	1.138	2.590	0,959	20.033	47	952	20,3	–

- **Efetividade:** na receita da busca, as três ficam a menos de 2% entre si no MAE e batem a persistência no RMSE (≈ 12% menor), mas não no MAE. Na receita de referência, as três batem a persistência nas duas métricas; GRU e LSTM ficam próximas e a SimpleRNN tem MAE 13% maior. A GRU é a melhor nas duas receitas.
- **Custo:** a SimpleRNN usa cerca de 1/3 dos parâmetros da GRU e menos da metade do tempo por época. GRU e LSTM custam quase o mesmo por época na CPU, com a GRU tendo 3/4 dos parâmetros da LSTM. A inferência fica abaixo de 0,2 ms por previsão em todas.
- A receita de treino pesou mais que a célula: a GRU de referência tem MAE 28% menor que a GRU da receita da busca.

5.2 Tamanho da janela e dependências de longo prazo

Tabela 3. Efeito da janela (SimpleRNN, 1 × 54).

Janela	MAE	RMSE	R^2	Épocas	Treino (s)	ms/previsão
7 dias	1.559	3.061	0,944	43	140	0,056
14 dias	1.579	3.020	0,945	50	179	0,058
30 dias	**1.566**	**2.725**	**0,955**	**31**	**158**	**0,111**

A janela de 30 dias reduz o RMSE em 11% em relação à de 7 dias, com MAE praticamente igual: a informação do último mês diminui sobretudo os erros grandes (mudanças de nível e dias atípicos), o que indica dependência útil além do ciclo semanal. O custo de inferência dobra e o de treino quase não muda; não houve sinal de instabilidade ou de overfitting maior. Janelas mais longas não foram testadas, pois exigem mais dias consecutivos observados numa série descontínua. O horizonte é t+1, adequado ao planejamento diário.

5.3 Profundidade, largura e custo

Tabela 4. Capacidade × custo (SimpleRNN, W = 30).

Variante	Parâmetros	MAE	RMSE	Épocas	Treino (s)	ms/previsão
1 camada × 54	3.727	1.566	2.725	31	149	0,106
2 camadas × 54	**9.613**	**1.493**	**2.604**	**50**	**454**	**0,137**
3 camadas × 54	15.499	1.503	2.667	37	513	0,210
1 camada × 32	1.505	1.713	3.238	9	40	0,070
1 camada × 64	5.057	1.598	2.768	50	262	0,100
1 camada × 128	**18.305**	**1.514**	**2.636**	**50**	**395**	**0,115**

A segunda camada reduz o MAE em 4,7% com 2,6× os parâmetros e 3× o tempo de treino; a terceira não acrescenta. Em largura, de 32 para 128 unidades são 12× mais parâmetros para 12% de MAE, e de 64 para 128 são 3,6× para 5%: retorno decrescente. A variante de 32 unidades parou em 9 épocas, indício de subajuste. A Figura 3 resume custo × efetividade de todas as variantes.

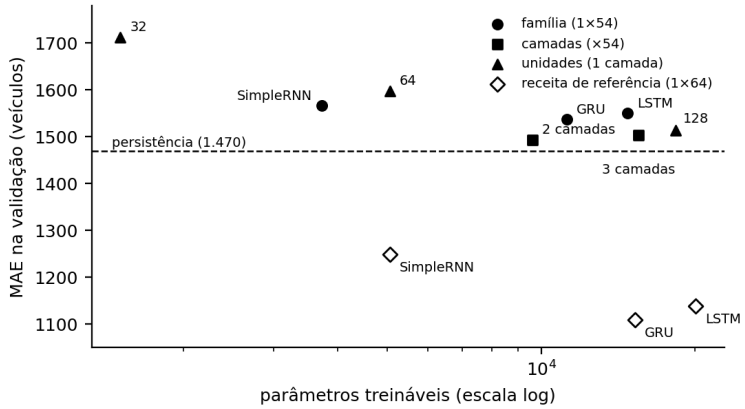


Figura 3. MAE de validação × parâmetros. Símbolos cheios: receita da busca; losangos vazados: receita de referência.

5.4 Curvas de treinamento e validação

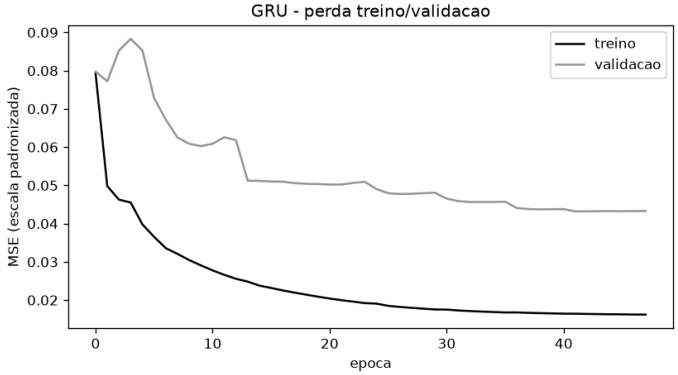


Figura 4. Perda (MSE padronizado) por época da GRU na receita de referência. Preto: treino; cinza: validação.

Nas três famílias, a perda de treino cai rápido e a de validação oscila nas primeiras épocas, depois desce e estabiliza. A validação fica acima do treino o tempo todo (no fim, ≈ 0,044 contra 0,020 na SimpleRNN, 0,016 na GRU e 0,014 na LSTM). A distância cresce com a capacidade e indica overfitting leve, mas a validação não volta a subir, e o early stopping guarda os melhores pesos (GRU parou em 48 épocas, LSTM em 47). A SimpleRNN usou as 60 épocas e ainda melhorava devagar. As curvas das três estão em `results/figures/`.

6. Avaliação final no teste

Modelo final: GRU, W = 30, 1 × 64, 15.233 parâmetros. O teste foi usado uma única vez em cada protocolo, sem ajustes posteriores.

Tabela 5. Desempenho no teste (veículos/dia).

Protocolo	Modelo	MAE	RMSE	R^2	MAE vs. persistência
Cronológico	Persistência	1.536	3.303	0,924	–
	Média móvel (30 dias)	1.831	4.099	0,884	+19%
	GRU final	**1.126**	**2.773**	**0,947**	**−27%**
Por grupos (praças novas)	Persistência	1.774	3.699	0,921	–
	Média móvel (30 dias)	2.028	4.423	0,888	+14%
	GRU final	**1.469**	**3.276**	**0,938**	**−17%**

- O modelo bate as duas réguas nos dois protocolos. No cronológico, o erro médio de 1.126 veículos equivale a ≈ 8,5% do volume médio de uma praça.
- No cronológico, validação (1.108) e teste (1.126) ficaram próximos: a escolha pela validação não a superajustou. Em praças novas, o MAE sobe de 1.101 (validação) para 1.469 (teste), o que mostra dependência do grupo de praças sorteado.
- A persistência já tem R^2 de 0,92; por isso o R^2 isolado não comprova qualidade, e a comparação relevante é o erro relativo à régua.

7. Limitações e conclusões

Limitações.

- Sem GPU: a busca teve 15 tentativas em metade do treino, não superou a configuração de referência e não amostrou a LSTM.
- Uma semente e sem validação cruzada: não há medida de variância, e diferenças abaixo de 2% não são conclusivas.
- Horizonte de um dia; não há previsão de múltiplos passos.
- Sem informação de feriados: os maiores erros tendem a ocorrer em dias atípicos (Réveillon, Carnaval, eventos).
- Janelas com dias faltantes são descartadas, e praças com menos de 180 dias ficam fora.
- No protocolo por grupos, a divisão é só por praça: treino e teste cobrem as mesmas datas.

Conclusões.

- As redes recorrentes superaram a persistência nos dois protocolos, com MAE 27% menor no futuro de praças conhecidas e 17% menor em praças novas.
- A GRU foi a melhor família nas duas receitas, por margem pequena. A SimpleRNN entrega erro próximo com cerca de 1/3 dos parâmetros e é a opção de melhor custo-efetividade.
- A janela de 30 dias foi o fator mais consistente para reduzir erros grandes. Profundidade e largura têm retorno decrescente.
- A receita de treino (otimizador, batch, regularização) pesou mais que a escolha da célula: a configuração de referência teve MAE 29% menor que a vencedora da busca.
- Trabalhos futuros: busca maior com GPU, validação temporal com várias origens e sementes, previsão de vários dias e variáveis de feriado.

Reprodutibilidade: ambiente em `requirements.lock.txt`; ordem de execução no `README.md` (`download_data.py` → `preprocess.py` → `dataset.py` → `train.py` → `optuna_search.py` → `experimentos.py` → `avaliar_teste.py`). Decisões sobre os dados em `docs/decisoes_dados.md`.