INSTITUTO FEDERAL
Goiás
Câmpus Goiânia

Previsão de volume de tráfego em praças de pedágio

Comparando redes recorrentes:
SimpleRNN, GRU e LSTM

Daniel Flavio e Guilherme Martins

Deep Learning · Instituto Federal de Goiás · Outubro de 2026

O PROBLEMA

Prever o movimento de amanhã

Para cada praça de pedágio, queremos saber quantos veículos vão passar **no dia seguinte** — usando os dias anteriores.

Dias anteriores
volume da praça

→

Próximo dia
a previsão

É prever um número, não uma categoria. Por isso a tarefa é de **regressão**, e não de classificação.

OS DADOS

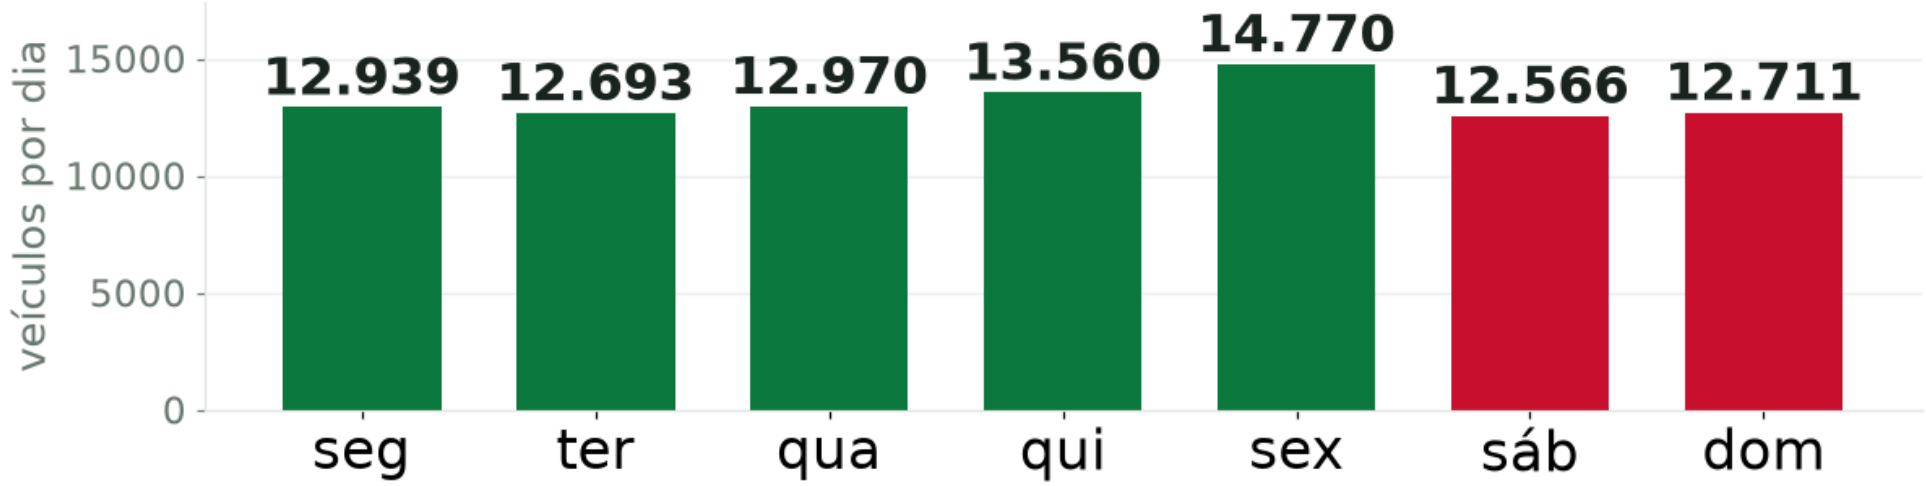
Dados públicos da ANTT, de 2024 a 2026

9,2 mi
linhas no arquivo original

345
praças

974
dias acompanhados

43
concessionárias



Fonte: dados.gov.br · "impressão digital" dos arquivos registrada

O QUE OS DADOS ENSINARAM

Dois achados mudaram o plano

1 **A série é diária.** A coluna chamada *mes_ano* guardava, na verdade, uma data por dia. Se tivéssemos tratado como mensal, perderíamos o efeito do dia da semana.

2 **A série é descontínua.** Só 47 das 345 praças têm o período inteiro. Metade tem menos de um ano — praças novas entraram no meio do caminho.

Por isso, um modelo por praça seria inviável. Adotamos **um único modelo, treinado com todas as praças**.

A MODELAGEM

O que o modelo enxerga

Entrada — 13 sinais por dia

4 de volume: carros de passeio, comerciais, motos e o total.

9 de calendário: dia da semana e época do ano.

Janela → resposta

Uma janela de **N dias** entra na rede. A saída é **um número**: o total de veículos do dia seguinte.

janela de N dias × 13 sinais → total do dia seguinte

MÉTODO

Avaliar série temporal tem regras

1. **Treino, validação e teste em ordem de data.** O teste é o futuro — ninguém viu antes.
2. **Nada é embaralhado.** A ordem dos dias nunca é quebrada.
3. **A normalização usa só o treino.** Usar o futuro aqui faria o resultado mentir.
4. **Janela só vale se todos os dias existem.** Não preenchemos buraco com dado inventado.

A RÉGUA

Antes de elogiar o modelo: repetir o último dia

A previsão mais simples que existe é dizer que amanhã será igual a hoje. Um modelo só tem valor se **bater essa régua**.

1.470

erro médio da régua (em veículos)

0,94

R^2 da régua

Ou seja: **um R^2 alto aqui não prova nada sozinho**. É exatamente por isso que a régua existe.

AS TRÊS ARQUITETURAS

Como cada rede guarda o passado

SimpleRNN

Uma memória curta e simples. É a mais rápida, mas esquece o passado distante.

GRU

Portões que decidem o que lembrar e o que descartar. Equilíbrio entre memória e custo.

LSTM

Memória de longo prazo com três portões. A mais poderosa — e a mais pesada.

Mesmas entradas, mesmos dados, mesma semente. **Muda só a célula.** É isso que torna a comparação justa.

AJUSTE AUTOMÁTICO

Em vez de chutar, testar com método

Optuna

Uma busca testa combinações de parâmetros e **mata cedo** as que vão mal. A escolha usa apenas a **validação**.

O que medimos

O erro (RMSE) na validação. O teste fica intocado até o fim — sem exceção.

Ressalva honesta Sem placa de vídeo, a busca rodou reduzida: 15 tentativas, usando parte do treino. Ela serve para **comparar** — o modelo final é retreinado com os dados completos.

RESULTADOS

Quem ganha: SimpleRNN, GRU ou LSTM?

ARQUITETURA	MAE	RMSE	PARÂMETROS	TREINO
GRU	**1.537**	**2.702**	11.233	9 min
LSTM	1.550	2.747	14.743	7 min
SimpleRNN	1.566	2.725	3.727	3 min

Empate técnico: as três ficam muito próximas. O SimpleRNN chega perto gastando **um terço dos parâmetros**.

Este número vem da **receita controlada** (a vencedora da busca), usada aqui só para isolar a arquitetura. A receita do modelo final é outra — e rende **melhor** (slide 13).

RESULTADOS

Quanto passado olhar — e qual tamanho ter

Quanto passado olhar

JANELA	RMSE
30 dias	**2.725**
14 dias	3.020
7 dias	3.061

Quantas camadas

CAMADAS	MAE
2	**1.493**
3	1.503
1	1.566

Janela mais longa ajuda de verdade. E **duas camadas** batem uma — mas a terceira não acrescenta.

RESULTADOS

Desempenho tem preço

UNIDADES	PARÂMETROS	MAE	TREINO	POR PREVISÃO
32	1.505	1.713	1 min	0,07 ms
64	5.057	1.598	4 min	0,10 ms
128	18.305	**1.514**	7 min	0,12 ms

Mais unidades melhoram o erro — mas o custo cresce **desproporcional**: 12 vezes mais parâmetros para ganhar cerca de 12% de MAE.

RESULTADO FINAL

O número que vale: o teste

Futuro da mesma praça

MODELO	MAE	R^2
Repetir o último dia	1.536	0,92
Média dos últimos dias	1.831	0,88
GRU (final)	**1.126**	**0,95**

Praças novas

MODELO	MAE	R^2
Repetir o último dia	1.774	0,92
Média dos últimos dias	2.028	0,89
GRU (final)	**1.469**	**0,94**

O modelo bate a régua nos dois cenários — com vantagem menor em **praças novas**.

Receita final: **GRU, janela 30, 1 camada, 64 unidades (Adam)** — a melhor validação entre todos os treinos.

FECHAMENTO

O que aprendemos e o que falta

Aprendemos

As redes recorrentes superaram a régua. A diferença entre as três famílias, porém, é pequena — e isso também é um resultado.

Limitações

Sem placa de vídeo, a busca foi reduzida. Não fizemos validação cruzada. E só prevemos um dia à frente.

Próximo passo: GPU e previsão de vários dias à frente.