Deep Learning · IFG

Previsão de volume de tráfego em praças de pedágio

Comparando redes recorrentes: SimpleRNN · GRU · LSTM

Daniel Flavio e Guilherme Martins · Instituto Federal de Goiás · Outubro de 2026

O problema

Prever o movimento de amanhã

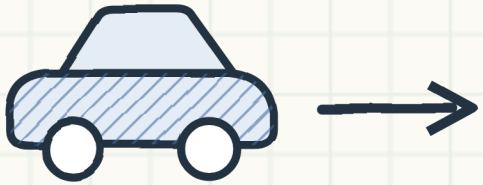
Para cada praça de pedágio, queremos saber quantos veículos vão passar no dia seguinte — usando os dias anteriores.

Dias anteriores
volume da praça

→

Próximo dia
a previsão

É prever um número, não uma categoria. Por isso a tarefa é de regressão.



Os dados

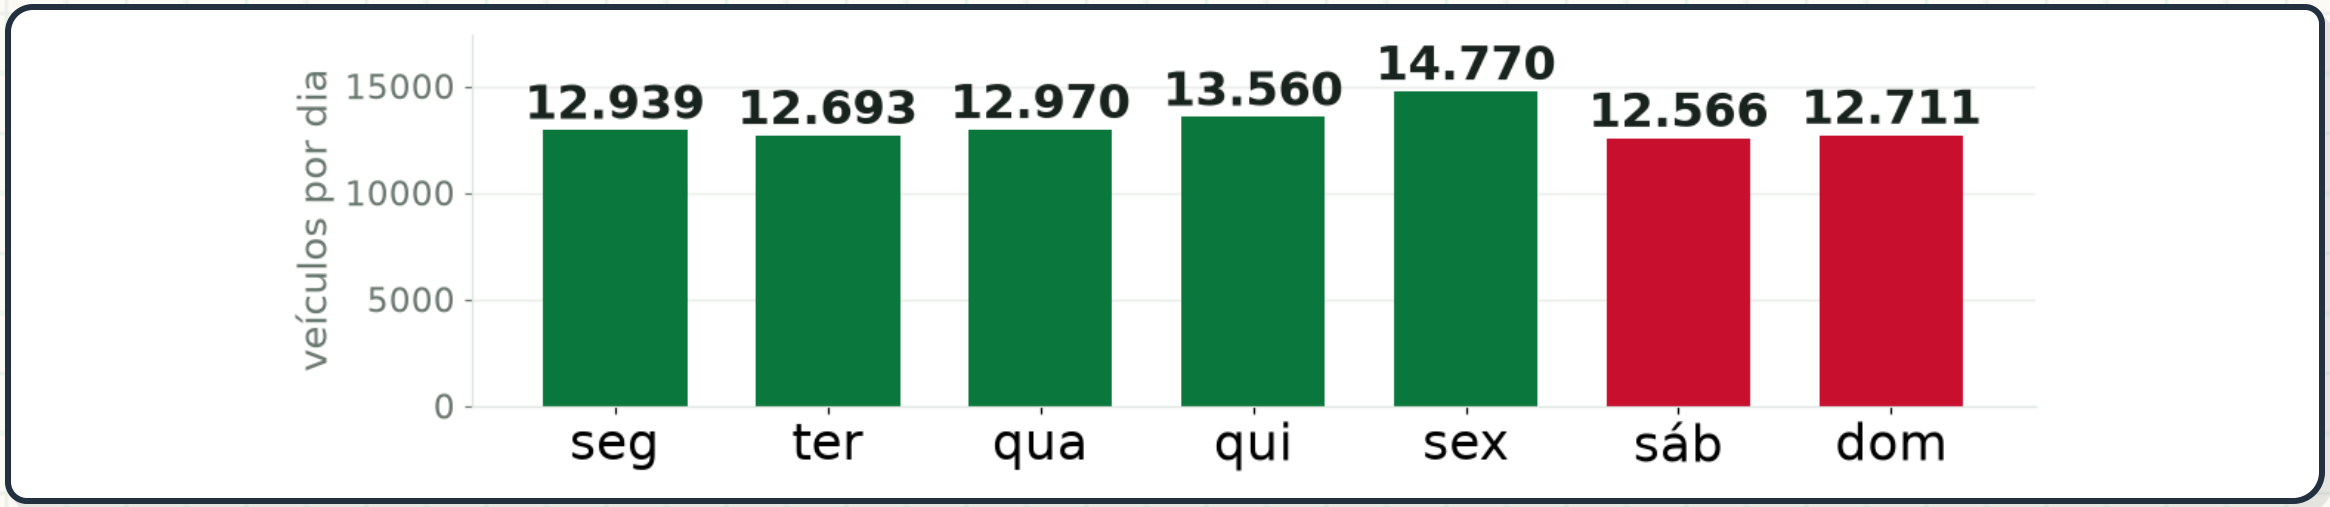
Dados públicos da ANTT, de 2024 a 2026

9,2 mi
linhas no arquivo original

345
praças

974
dias acompanhados

43
concessionárias



Fonte: dados.gov.br · "impressão digital" dos arquivos registrada

O que os dados ensinaram

Dois achados mudaram o plano

1 · A série é diária

A coluna chamada *mes_ano* guardava, na verdade, uma data por dia. Tratar como mensal apagaria o efeito do dia da semana.

2 · A série é descontínua

Só **47 das 345** praças têm o período inteiro. Metade tem menos de um ano — praças novas entraram no meio.

Consequência: um modelo por praça seria inviável. Treinamos um único modelo, com todas as praças.

A modelagem

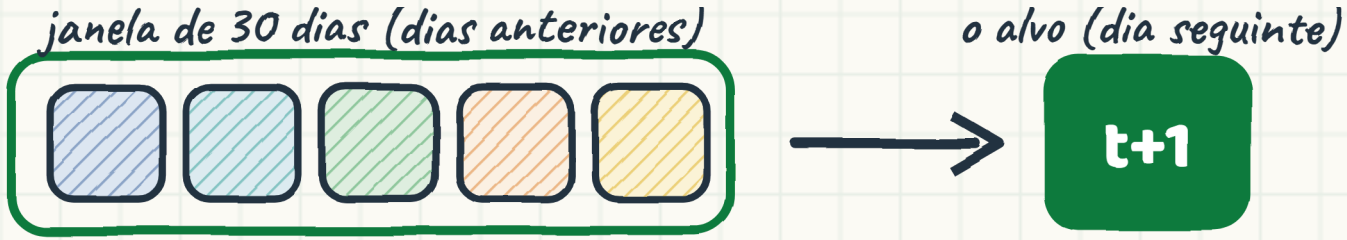
O que o modelo enxerga

13 sinais por dia

4 de volume: passeio, comercial, motos e o total.
9 de calendário: dia da semana e época do ano.

Janela → resposta

Uma **janela de N dias** entra na rede. A saída é **um número**: o total de veículos do dia seguinte.



A janela desliza 1 dia por vez — cada passo vira um exemplo de treino.

Método

Avaliar série temporal tem regras

- **Treino, validação e teste em ordem de data** — o teste é o futuro.
- **Nada é embaralhado:** a ordem dos dias nunca quebra.
- **A normalização usa só o treino.**
- **Janela só vale se todos os dias existem.**

A régua

Antes de elogiar: repetir o último dia

A previsão mais simples que existe é dizer que amanhã será igual a hoje. Um modelo só tem valor se **bater essa régua**.

1.470

erro médio da régua (veículos)

0,94

R^2 da régua

Ou seja: um R^2 alto aqui não prova nada sozinho. É por isso que a régua existe.

As três arquiteturas

Como cada rede guarda o passado

SimpleRNN

Memória curta e simples. A mais rápida, mas esquece o passado distante.

GRU

Portões que decidem o que lembrar e o que descartar. Equilíbrio entre memória e custo.

LSTM

Memória de longo prazo com três portões. A mais poderosa — e a mais pesada.

Mesmas entradas, mesmos dados, mesma semente. Muda só a célula.



Ajuste automático

Em vez de chutar, testar com método

Optuna

Uma busca testa combinações de parâmetros e **mata cedo** as que vão mal. A escolha usa apenas a **validação**.

O que medimos

O erro (RMSE) na validação. O teste fica intocado até o fim — sem exceção.

Ressalva honesta Sem GPU, a busca rodou reduzida: **15 tentativas**, parte do treino. O modelo final é retreinado com os dados completos.

Resultados

Quem ganha: SimpleRNN, GRU ou LSTM?

ARQUITETURA	MAE	RMSE	PARÂMETROS	TREINO
GRU	**1.537**	**2.702**	11.233	9 min
LSTM	1.550	2.747	14.743	7 min
SimpleRNN	1.566	2.725	3.727	3 min

Empate técnico. O SimpleRNN chega perto gastando um terço dos parâmetros.

Resultados

Quanto passado olhar — e qual tamanho ter

Quanto passado olhar

JANELA	RMSE
30 dias	**2.725**
14 dias	3.020
7 dias	3.061

Quantas camadas

CAMADAS	MAE
2	**1.493**
3	1.503
1	1.566

Janela mais longa ajuda de verdade. E duas camadas batem uma — a terceira não acrescenta.

Resultados

Desempenho tem preço

UNIDADES	PARÂMETROS	MAE	TREINO	POR PREVISÃO
32	1.505	1.713	1 min	0,07 ms
64	5.057	1.598	4 min	0,10 ms
128	18.305	**1.514**	7 min	0,12 ms

Mais unidades melhoram o erro — mas o custo cresce desproporcional: 12× mais parâmetros para ~12% de MAE.

Resultado final

O número que vale: o teste

Futuro da mesma praça

MODELO	MAE	R^2
Repetir o último dia	1.536	0,92
Média dos últimos dias	1.831	0,88
GRU (final)	**1.126**	**0,95**

Praças novas

MODELO	MAE	R^2
Repetir o último dia	1.774	0,92
Média dos últimos dias	2.028	0,89
GRU (final)	**1.469**	**0,94**

O modelo bate a régua nos dois cenários — e em praças novas a vantagem é menor, como esperado.

Fechamento

O que aprendemos e o que falta

Aprendemos

As redes recorrentes superaram a régua. A diferença entre as três famílias, porém, é pequena — e isso também é um resultado.

Limitações

Sem placa de vídeo, a busca foi reduzida. Não fizemos validação cruzada. E só prevemos um dia à frente.

Obrigado! Perguntas?